会听会变声的智能终端 —— 项目技术细节速查

更新日期：2026-11-14　　用途：答辩速查、排障对照、写报告引用

0　一句话

所有计算都在 ROCK 5B+ 板子上完成，电脑只用来编辑代码和传文件。

```
电脑（Windows）                    ROCK 5B+（RK3588）
├── 编辑 .py 文件                  ├── 运行全部程序
├── scp 传到板子                   ├── 录音 / 识别 / 变声 / 播放
└── SSH 看日志                     ├── 驱动 SPI 屏幕
                                   └── 跑 NPU 上的模型
```

没有一步是在电脑上跑的 —— 包括音色注册（虽然是离线工具，但也是在板子上运行的）。

1　运行位置一览

环节	在哪	说明
录音	板子	USB 声卡 → ALSA → sounddevice
音量条 / 界面	板子	Python + PIL 渲染 → SPI
语音识别	板子 CPU	SenseVoice int8，sherpa-onnx
DSP 变声	板子 CPU	纯 numpy，相位声码器
音色注册	板子 CPU	一次性，ONNX Runtime 跑 CamPlus 与 tokenizer
音色克隆合成	板子 NPU	RKLLM + RKNN，C++ 引擎
播放	板子	生成 WAV → aplay
开机自启	板子	systemd

2　音频参数

环节	采样率	声道	格式
录音（麦克风）	48 kHz	单声道	float32
识别输入	16 kHz	单声道	sherpa-onnx 内部自动重采样
DSP 变声	48 kHz	单声道	与录音一致
MeloTTS 输出	44.1 kHz	单声道	备用，默认不启用
CosyVoice 输出	24 kHz	单声道	16-bit PCM
播放	任意	任意	aplay 自动转换

注意：录音是单声道。该 USB 声卡（C-Media 0d8c:0014）的采集只支持 1 通道。

3　分贝阈值（重点）

3.1　三组不同的分贝

名称	用途	范围
音量条映射	把 RMS 变成 0~1 画音量条	固定 −70 ~ −20 dBFS
自适应 VAD 门限	判断这一帧是不是有人在说话	动态，随环境噪声变
静音裁剪阈值	剪掉首尾静音	固定 −40 dBFS（线性 0.01）

3.2　音量条怎么算

```
db    = 20 × log10(rms)
ratio = (db − (−70)) / ((−20) − (−70))     # 即 (db + 70) / 50
ratio = 限制到 [0, 1]
```

底噪 −78 dBFS → ratio = 0（不显示）；正常说话约 −20 dBFS → ratio = 1（满格）。

3.3 自适应 VAD 门限

每一轮开始前先安静录 0.6 秒，算出噪声基线 N：

```
N = 分块 RMS 的 dB 值的中位数        # 分块 50 ms，用中位数抗突发噪声
门限 T = max(N + margin, floor)
```

参数	代码默认	服务实际使用	含义
margin	8 dB	15 dB	比噪声高多少才算说话
floor	−40 dBFS	−35 dBFS	绝对下限

举例（服务配置：margin 15、floor −35）：

环境噪声	计算	门限	正常说话 −20 dBFS 能过吗
−55 dBFS	max(−40, −35)	−35	能
−42 dBFS	max(−27, −35)	−27	能
−32 dBFS	max(−17, −35)	−17	不能（会被判成静音）

门限的物理上限 = 说话音量 − 环境噪声（即信噪比）。环境太吵时 margin 调得越高，越容易把说话本身也判成静音。

3.4 为什么必须用自适应（踩过的坑）

早期用固定阈值 ratio ⩾ 0.18，反算成 dB 是 −61 dBFS。

```
环境噪声 -32 dBFS → ratio = 0.76
0.76 远大于 0.18  →  检测器永远判定「有人在说话」
                  →  静音永远累计不起来
                  →  录音只能等时长上限，白等十几秒
```

3.5 其他与电平相关的参数

参数	值	说明
录音前校准时长	0.6 秒	屏幕提示保持安静
噪声分块长度	50 ms	计算噪声基线的窗口
电平平滑系数	0.75 / 0.25	指数平滑，避免单块 21 ms 抖动
最少有声时长	0.2 秒	累积这么久才开始计静音
静音裁剪阈值	0.01 线性	即 −40 dBFS，两端各留 0.3 秒
麦克风增益	28 / 35	出厂值是 0，必须显式设置
扬声器音量	37 / 37	满量程

3.6 实测电平参考

场景	峰值	RMS
安静房间底噪	—	−70 ~ −78 dBFS
正常说话（增益 28）	−3 ~ −6 dBFS	−19 ~ −28 dBFS
说话很轻或离得远	−15 dBFS	−40 dBFS 以下（识别容易失败）

若看到环境噪声基线 −68 dBFS 这种数字，说明麦克风可能没接通 —— 真实房间底噪不会这么低。

4 完整流程（USB 触发模式）

步骤	做什么
① 待机	屏幕显示「请插上声卡」；程序每 0.4 秒检查 /proc/asound/card*/usbid 是否有 0d8c:0014
② 插上声卡	等待设备枚举，重新解析 ALSA 卡号和 sounddevice 索引，设置麦克风增益 28、扬声器音量 37；一声短嘀（1200 Hz）；屏幕显示音量条
③ 说话	48 kHz 单声道录音，实时电平驱动音量条
④ 拔下声卡	检测到缓冲区 0.5 秒没有新数据即判定设备断开，立即结束录音；裁掉首尾静音（阈值 −40 dBFS，各留 0.3 秒）
⑤ 识别	SenseVoice：48 kHz 内部重采样到 16 kHz，输出文字；耗时约 0.3 秒（17~20 倍速）；屏幕显示识别中
⑥ 指令判断	顺序不能乱。命中关机词则断电；命中切换词且音色不同则换音色并回①；否则继续
⑦ 显示	屏幕整屏只显示识别到的这句话
⑧ 变声	瓦瓦：DSP 相位声码器 0.4 秒；曼波：CosyVoice2 8~20 秒（上半文字 + 下半进度条）
⑨ 等待播放	屏幕上半显示识别文字、下半提示「请插上声卡播放」；等待声卡重新插入并重新解析设备
⑩ 播放	从声卡输出变声结果
⑪ 收尾	屏幕提示「请拔下声卡」，拔下后回①

5 模型清单

模型	作用	参数量	精度	跑在哪	耗时
SenseVoice	语音转文字	234 M	int8	CPU	0.3 s / 6 秒音频
DSP 相位声码器	波形变调 + 共振峰搬移	0	—	CPU（numpy）	0.4 s / 6 秒音频
CosyVoice2	文字转带指定音色的语音	约 781 M	W8A8 + FP16	NPU	8~20 s
MeloTTS	普通语音合成	约 43 M	FP16	NPU	4.5 倍速（备用）

CosyVoice2 内部拆分：

组件	参数量	跑在哪
Qwen2 语言模型	约 509 M	RKLLM（NPU0+1）
嵌入表（text / speech / control）	142.0 M	CPU 内存映射
语音 tokenizer	123.7 M	NPU
Flow Estimator	约 86.9 M	NPU2
Flow Encoder	约 53.4 M	NPU2
HiFT Decoder	约 20.6 M	NPU2
CampPlus 说话人编码器	6.9 M	NPU
HiFT F0	约 3.3 M	NPU2

6 两条变声路线对照

项目	瓦瓦（DSP）	曼波（CosyVoice）
输入	波形	文字
输出	波形	波形
保留原语调	完整保留	丢失
复现特定音色	只能整体升调	可克隆任意音色
参数量	0	781 M
处理耗时	0.4 秒	8~20 秒
峰值内存	约 0.4 GB	约 1.6 GB
可调参数	5 个预设（+8 ~ +25 半音）	由参考音频决定
实时性	快 15 倍	慢于实时

为什么两条都留着：取舍恰好互补，演示时对比着讲最能说明信号处理与神经网络两条技术路线的本质区别。

7 语音指令

说什么	效果
我是曼波 / 切换到音色 1 / 哈基米	切到曼波音色
我是瓦瓦 / 切换到音色 2	切到瓦瓦音色
曼波关机（曼波音色下）	断电
瓦瓦关机（瓦瓦音色下）	断电
任意句子	用当前音色念出来

同音容错（ASR 实测收到的错误写法）：

正确说法	实测错误写法	匹配用的字符类
曼波	慢播 / 漫播 / 漫步	[曼慢漫满蛮蔓][波播拨博簸步]
瓦瓦	娃娃 / 哇哇	[瓦娃哇挖袜][瓦娃哇挖袜]
音色 1	银色 1	[音银][色瑟][1 一壹]

幂等规则：当前已是该音色时，说的话当普通句子念出来，不重复切换。

8 部署

```
# 一键应用（重装服务 + 重启 + 校验版本）
cd ~/proj/kskbl
sudo bash deploy/apply.sh

# 看日志
journalctl -u kskbl -f

# 停止（手动调试前必须停，否则抢屏幕和声卡）
sudo systemctl stop kskbl
```

服务实际参数：

参数	值	含义
--trigger	usb	USB 声卡插拔触发
--usb-id	0d8c:0014	声卡 VID:PID
--duration	30	最长录音（保险）
--silence-stop	0	关闭静音自动停（只听拔卡）
--noise-margin	15	说话门限 = 噪声 + 15 dB
--speech-floor	−35	说话门限的绝对下限

参数	值	含义
--mic-gain	28	麦克风增益
--voice	wawa	默认音色

9 关键文件

文件	作用
src/kskbl/app.py	状态机、语音指令、流程编排
src/kskbl/audio.py	音频 I/O、自适应 VAD、静音裁剪
src/kskbl/voice.py	相位声码器、共振峰搬移、基频估计
src/kskbl/cosy.py	CosyVoice2 调用封装
src/kskbl/asr.py	SenseVoice 识别封装
src/kskbl/render.py	七种界面渲染
src/kskbl/st7789.py	SPI 屏驱动
tools/cosy_register.py	音色注册（一次性）
deploy/	systemd 服务 + 免密关机 + 部署脚本

10 三句话记住这个项目

第一句：软件是一个状态机加五个模块，调度和处理分离，全部跑在板子上。

第二句：变声有两条路 —— DSP 零参数 0.4 秒但改不了音色，CosyVoice 781 M 能克隆音色但丢语调。

第三句：识别 234 M 跑 CPU 17~20 倍速，克隆 781 M 跑 NPU 首包 1.9 秒。